BIN702 - Série d'exercices sur les structures secondaires d'ARN

Manuel Lafond

Rappel : la récurrence de Nussinov calcule $V[i,j]$ pour tout i,j, où $V[i,j]$ est le nombre maximum d'appariements pour $S[i..j]$. On a $V[i,j]=0$ pour $i \geq j$ et sinon,

$$V[i,j] = max \begin{cases} V[i+1,j] \\ \max_{k=i+1..j}(V[i+1,k-1]+V[k+1,j]+\delta_{ik}) \end{cases}$$

où $\delta_{ik}=1$ si $S[i]$ s'apparie avec $S[k]$, et $\delta_{ik}=-\infty$ sinon.

Exercice 1: En classe, nous avons présenté une version récursive de l'algorithme de Nussinov. Écrivez le pseudo-code d'une version itérative de l'algorithme. C'est-à-dire, calculez les valeurs de la table de programmation dynamique avec des boucles, sans avoir recours à des appels récursifs.

Exercice 2: La récurrence de Nussinov calcule un nombre maximum d'appariements. Supposons plutôt que nous avons une matrice M qui donne un score d'appariement $M[a,b]$ pour chaque paire de nucléotides a,b. Donnez une récurrence qui permet de maximiser la somme des scores des appariements, toujours avec condition d'emboîtement des appariements.

Exercice 3: Considérez la séquence d'ARN ci-dessous avec ses paires de bases inférées. Dessinez l'arbre correspondant au parenthésage de ces appariements, puis dessinez un repliement en 2D qui illustre les sous-structures principales de la molécule.

Exercice 4: Supposons que l'on veut interdire les boucles multiples dans le contexte de maximisation du nombre d'appariements $A-U$ et $C-G$. Donnez un algorithme en temps $O(n^2)$ qui trouve ce maximum.

Indice : sans multi-boucle, un appariement ne peut pas avoir plus d'un appariement se trouvant directement à l'intérieur.

Exercice 5: Considérez l'algorithme de Zuker, dans lequel on avait une récurrence pour $V[i,j]$ avec quatre cas possibles, un pour chaque sous-structure T, E, B et M. Les multi-boucles (M) étaient le cas le plus complexe à gérer, alors supposons qu'on s'en débarasse et qu'on ne permettre que les cas T, E et B. Décrivez la structure des arbres d'appariements qui sont possibles avec cette contrainte, puis décrivez informellement la forme des molécules d'ARN qui peuvent résulter de l'algorithme avec cette contrainte.

Exercice 6: La récurrence de l'algorithme de Nussinov pour $V[i,j]$ était basée sur deux cas possibles : soit i n'est pas apparié, ou soit i est apparié avec un certain $k \in \{i+1, \ldots, j\}$.
Il existe une autre version (équivalente) de la récurrence de Nussinov. Celle-ci est basée sur une autre séparation des cas possibles : soit i est apparié avec j, ou bien i n'est pas apparié avec j. Dans ce deuxième cas, il doit exister un $k \in \{i, \ldots, j-1\}$ tel que aucun appariement ne traverse k, c'est-à-dire que tous les appariements sont entre i et k, ou entre $k+1$ et j.

Donnez une récurrence de programmation dynamique avec cette séparation en deux cas.

Exercice 7: *NOTE :* je n'ai même pas essayé de faire l'exercice suivant. Il me paraît tout à fait faisable, mais je n'ai pas encore la solution. Essayez-le à vos risques et périls !

Supposons que l'on veut maximiser le nombre d'empilements, c'est-à-dire le nombre d'appariements (i, j) tels que $(i+1, j-1)$ sont aussi appariés. Donnez un algorithme qui maximise le nombre d'empilements.