BIN702 - Série d'exercices sur les structures secondaires d'ARN

Manuel Lafond

Rappel : la récurrence de Nussinov calcule $V[i,j]$ pour tout i,j, où $V[i,j]$ est le nombre maximum d'appariements pour $S[i..j]$. On a $V[i,j]=0$ pour $i \geq j$ et sinon,

$$V[i,j] = max \begin{cases} V[i+1,j] \\ \max_{k=i+1..j}(V[i+1,k-1]+V[k+1,j]+\delta_{ik}) \end{cases}$$

où $\delta_{ik}=1$ si $S[i]$ s'apparie avec $S[k]$, et $\delta_{ik}=-\infty$ sinon.

Exercice 1: En classe, nous avons présenté une version récursive de l'algorithme de Nussinov. Écrivez le pseudo-code d'une version itérative de l'algorithme. C'est-à-dire, calculez les valeurs de la table de programmation dynamique avec des boucles, sans avoir recours à des appels récursifs.

<u>Solution</u>. Il faut seulement s'assurer de parcourir la table de programmation dynamique en remplissant diagonale par diagonale. La variable d représentera l'indice (i.e. le décalage horizontal) de la diagonale courante. On ajuste i et j en conséquence.

```
fonction nussi3(S)
    V = [,];
    pour d = 1..n faire
        pour i = 1..n − d + 1 faire
            j = i + d − 1;
            si i ≥ j alors
                V[i, j] = 0;
            sinon
                V[i, j] = V[i + 1, j];
                pour k = i + 1..j faire
                    si S[i] s'apparie avec S[k] alors
                        tmp = V[i + 1, k − 1] + V[k + 1, j] + 1;
                        V[i, j] = max(V[i, j], tmp);
                fin
                ; // Note: si on voulait faire du backtracking,
                  c'est ici qu'il faudrait mémoriser le cas qui
                  a mené à la vaeur de V[i, j]
            fin
        fin
    fin
    return V[1, n];
```

□

Exercice 2: La récurrence de Nussinov calcule un nombre maximum d'appariements. Supposons plutôt que nous avons une matrice M qui donne un score d'appariement $M[a, b]$ pour chaque paire de nucléotides a, b. Donnez une récurrence qui permet de maximiser la somme des scores des appariements, toujours avec condition d'emboîtement des appariements.

<u>Solution</u>. Une fois qu'on a bien compris, c'est trop facile !

$$V[i,j] = max \begin{cases} V[i+1,j] \\ \max_{k=i+1..j}(V[i+1,k-1] + V[k+1,j] + M[S[i],S[k]]) \end{cases}$$

□

Exercice 3: Considérez la séquence d'ARN ci-dessous avec ses paires de bases inférées. Dessinez l'arbre correspondant à ces appariements, puis dessinez un repliement en 2D qui illustre les sous-structures principales de la molécule.

<u>Solution</u>. Voici, avec les appariements numérotés (je ne dessine pas tous les nucléotides, seulement les appariements) :

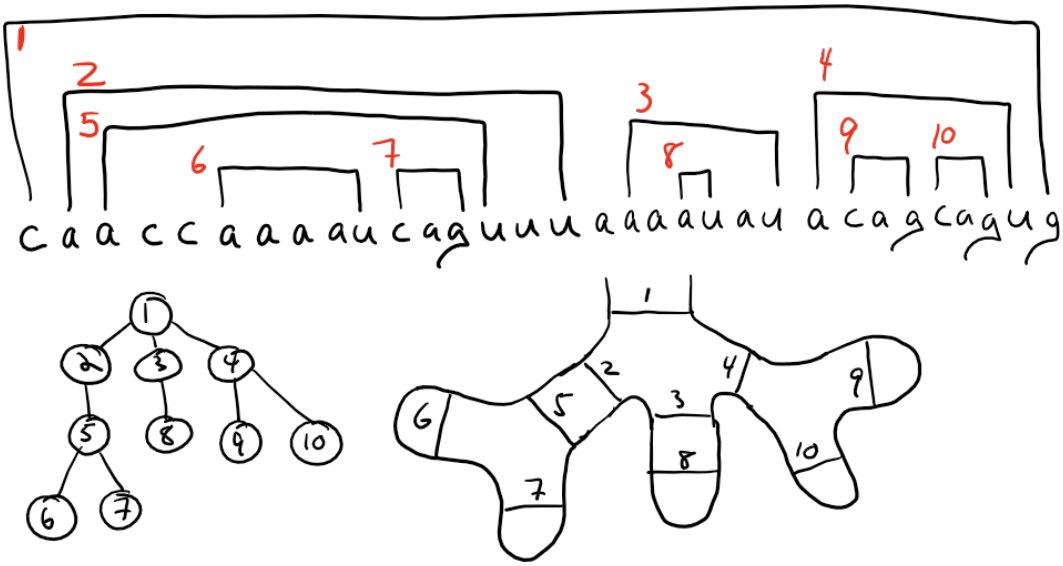

□

Exercice 4: Supposons que l'on veut interdire les boucles multiples dans le contexte de maximisation du nombre d'appariements $A-U$ et $C-G$. Donnez un algorithme en temps $O(n^2)$ qui trouve ce maximum.

Indice : sans multi-boucle, un appariement ne peut pas avoir plus d'un appariement se trouvant directement à l'intérieur.

<u>Solution</u>.

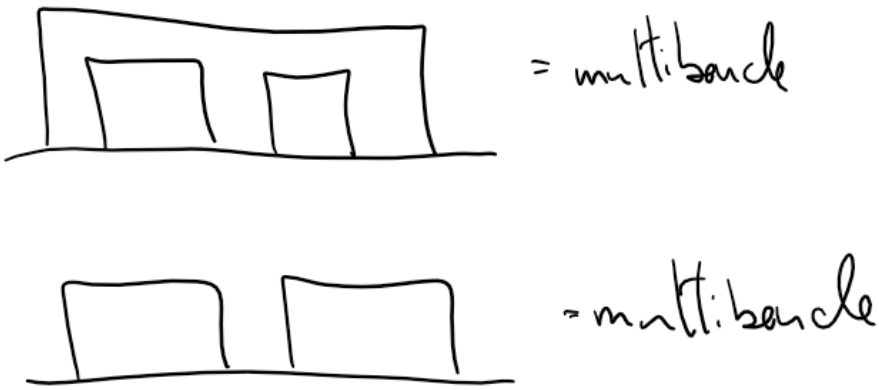

La figure illustre les imbrications interdites : il ne peut pas y avoir deux appariements au même niveau. Ceci dit, il y a au maximum un seul appariement qui n'est contenu dans aucun autre appariement (qui correspond à la racine de l'arbre correspondant). Comment le trouver ? Supposons qu'on sait que cet appariement est $A-U$. On observe que sans multi-boucle, il vaut mieux prendre le A le plus à gauche et le U le plus à droite. Ceci est vrai parce que chaque apparaiement autre sera à l'intérieur de ce $A-U$, et donc on maximisera les appariements possibles en prenant la paire $A-U$ la plus éloignée.

Par contre, on ne sait pas quels sont les caractères qui forment l'appariement au plus haut niveau. Ça pourrait être $A-U$ ou bien $C-G$. On essaie deux possibilités et on forme une récurrence, comme d'habitude.

Soit $V[i,j]$ le nombre maximum d'appariements sur $S[i..j]$. On pose $V[i,i]=0$ et $V[i,j]=V[j,i]$ si $i>j$.
Pour chaque appariement possible $X-Y$, soit i_X la position du premier X sur $S[i..j]$ et soit j_Y la position du dernier Y sur $S[i..j]$. Il est possible que $i_X > j_Y$, dans quel cas on inverse les deux positions. On a donc

$$V[i,j] = \max_{X-Y \text{ possible}} (1 + V[i_X+1, j_Y-1])$$

Puisque le nombre d'appariements possibles $X-Y$ est constant, chaque $V[i,j]$

peut se calculer en temps $O(1)$. Il y a $O(n^2)$ entrées à calculer, et donc on peut implémenter cette récurrence en temps $O(n^2)$.
Ce qui n'a pas été expliqué, c'est comment trouver i_X et j_Y. Une façon est de faire un prétraitement pour avoir accès à i_X en temps $O(1)$ pendant l'exécution de la récurrence. C'est-à-dire, on va d'abord préstocker, pour chaque position i et chaque caractère $X \in \{A, C, G, U\}$, la position i_X du prochain caractère X à partir de i. Je vous laisse l'exercice d'effectuer ce prétraitement, qui est facile à faire en temps $O(n^2)$. De la même façon, on peut préstocker tous les j_Y. Donc, ajouter un prétraitement $O(n^2)$ à un algorithme déjà $O(n^2)$ ne change pas la complexité.
Vous devriez vous demander pourquoi cette récurrence ne fonctionne pas si on permet les multi-boucles. □

Exercice 5: La récurrence de l'algorithme de Nussinov pour $V[i, j]$ était basée sur deux cas possibles : soit i n'est pas apparié, ou soit i est apparié avec un certain $k \in \{i + 1, \ldots, j\}$.
Il existe une autre version (équivalente) de la récurrence de Nussinov. Celle-ci est basée sur une autre séparation des cas possibles : soit i est apparié avec j, ou bien i n'est pas apparié avec j. Dans ce deuxième cas, il doit exister un $k \in \{i, \ldots, j - 1\}$ tel que aucun appariement ne traverse k, c'est-à-dire que tous les appariements sont entre i et k, ou entre $k + 1$ et j.
Donnez une récurrence de programmation dynamique avec cette séparation en deux cas.

<u>Solution</u>. Les deux cas sont illustrés dans la figure ci-dessous. Vous devriez prendre le temps de vous convaincre que le deuxième cas s'applique bel et bien. La récurrence correspondante est

$$V[i, j] = max \begin{cases} V[i + 1, j - 1] + \delta_{ij} \\ \max_{k=i..j-1}(V[i, k] + V[k + 1, j]) \end{cases}$$

□

Exercice 6: Considérez l'algorithme de Zuker, dans lequel on avait une récurrence pour $V[i, j]$ avec quatre cas possibles, un pour chaque sous-structure T, E, B et M. Les multi-boucles (M) étaient le cas le plus complexe à gérer, alors supposons qu'on s'en débarasse et qu'on ne permettre que les cas T, E et B. Décrivez la structure des arbres d'appariements qui sont possibles avec cette

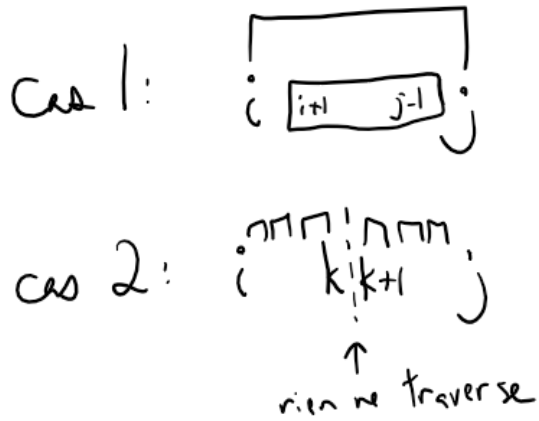

contrainte, puis décrivez informellement la forme des molécules d'ARN qui peuvent résulter de l'algorithme avec cette contrainte.

<u>Solution</u>. Puisqu'un noeud avec ≥ 2 enfants correspond à une multi-boucle, tout sommet de l'arbre aura 1 ou 0 enfants. Donc l'arbre est en fait un chemin. La structure de l'ARN aura une forme phallique (oui, phallique), i.e. ce sera essentiellement deux lignes droites jointes par une tige-boucle. $\square$

Exercice 7: Supposons que l'on veut maximiser le nombre d'empilements, c'est-à-dire le nombre d'appariements (i, j) tels que $(i + 1, j - 1)$ sont aussi appariés. Donnez un algorithme qui maximise le nombre d'empilements.
NOTE : je n'ai même pas essayé de faire l'exercice suivant. Il me paraît tout à fait faisable, mais je n'ai pas encore la solution. Essayez-le à vos risques et périls !

<u>Solution</u>. Finalement ce n'était pas si compliqué. Prenons l'approche habituelle de programmation dynamique et d'énumération des cas possibles. Soit $V[i, j]$ le nombre maximum d'empilements possibles sur $S[i..j]$. On a deux cas possibles :

a. i ne participe pas à un empilement. Dans ce cas, ce n'est même pas la peine d'apparier i et on peut donc supposer que i n'est pas apparié. Dans ce cas on a $V[i, j] = V[i + 1, j]$.
b. i participe à un empilement. Dans ce cas, il existe $k \geq i + 3$ tel que l'on peut former les appariements $(i, k), (i + 1, k - 1)$. On ne connaît pas k,

alors on les essaie tous. Ce cas peut être évalué avec

$$V[i,j] = \max_{k=i+3..j}(V[i+2,k-2] + V[k+1,j] + \delta(i,k,i+1,k-1)$$

où on définit $\delta(i,k,i+1,k-1) = 1$ si les paires $(S[i], S[k])$ et $(S[i+1], S[k-1])$ sont appariables, et sinon c'est $-\infty$.

Bref, la récurrence est

$$V[i,j] = max \begin{cases} V[i,j] = V[i+1,j] \\ \max_{k=i+3..j}(V[i+2,k-2] + V[k+1,j] + \delta(i,k,i+1,k-1) \end{cases}$$

ce qui peut se calculer en temps $O(n^3)$. $\square$