Phylogénétique

8 mars 202

Note : 2ème livrable du projet d'ici 19 mars
2e et 3e cycle : article

Phylogénétique : étude des relations évolutives entre éléments qui changent le temps. Ces élts sont appelés taxa (pluriel de taxon)

ex de taxa : espèces, gène, cellules, langages, clusters, ...

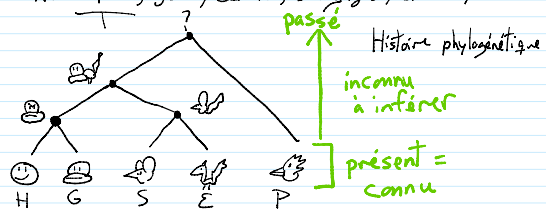

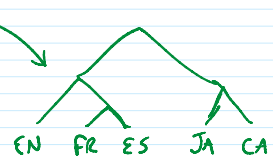

Supposition : les taxa évoluent en arbre et descendent d'un ancêtre commun unique.

Souvent : • un taxon ancestral donne lieu à 2 descendants
• branches étiquetées par une val. numérique représentant un temps d'évolution, un taux d'évol., ...

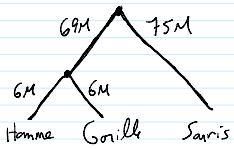

Feuilles = taxa du présent connus
Noeuds internes = taxa ancestraux du passé

Problème de la reconstruction phylogénétique

Entrée : ensemble F de taxa

Sortie : arbre T dont les feuilles sont F, représentant les relations évolutives les + plausibles entre F.
(+ possiblement longueurs des branches)

Pour nous, F = ensemble de séquences

Approches : ① Par distances
② Par caractères
③ Statistiques

① Approches par distances.
Soit $F = \{S_1, S_2, S_3, \dots, S_n\}$
On calcule D, la matrice de distances d'alignements (globaux)

• D_{ij} = coût min d'alignement entre S_i et S_j

Utopie : les distances d'alignement = distances dans l'arbre

	A	B	C
A	0	2	5
B		0	5
C			0

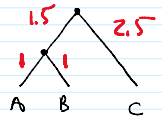

• dist entre 2 feuilles = dist d'align.
• les dist. feuille-racine sont égales (tous les taxas aux feuilles = même temps par rapport à la racine)

UPGMA (unweighted pair group method with arithmetic-mean)

- calculer D matrice dist
- considérer chaque colonne/rangée comme un noeud de l'arbre
- tant que D a plus d'une rangée
  - trouver le D_{AB} de valeur minimum
  - joindre A et B pour créer un nouvel elt qu'on appelle (AUB)
  - supprimer de D les rangées/colonnes A et B
  - ajouter une rangée/colonne (AUB)
  - joindre A et B dans la phylogénie
  - calculer les distances avec (AUB)
    - pour chaque C dans D

$D_{(A\cup B),C}$ = moyenne des distances des elts de A et B à C

$= \frac{1}{\#dist} \cdot \sum dists$

$= \frac{1}{|A\cup B| \cdot |C|} \sum_{x \in A\cup B} \sum_{y \in C} D_{xy}$

lmg : $O(n^2)$

S_1 AAAAA
S_2 AAACC
S_3 TAATTTT
S_4 TAAGCTT
S_5 GAACG

= supprimé

	S_1	S_2	S_3	S_4	S_5	S_1S_2	S_3S_4	$S_1S_2S_5$
S_1	0	2	5	5	3			
S_2		0	5	5	3			
S_3			0	2	5	5		
S_4				0	5	5		
S_5					0	3	5	
S_1S_2						0	5	
S_3S_4							0	5
$S_1S_2S_5$								0

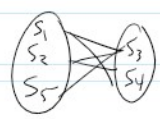

T

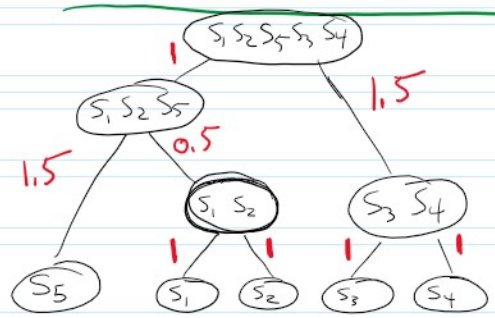

Arbre qui satisfait l'ultramétricité

- Exo : calculer complexité O sans compter le calcul de D
- Pour mettre à jour + vite : $D_{A\cup B,C} = \frac{|A| D_{AC} + |B| D_{B,C}}{|A|+|B|}$

vite $O(1)$

- Souhait : étiqueter les branches avec des longueurs qui satisfont l'utopie.

Une distance D est <u>ultramétrique</u> s'il existe un arbre T étiqueté t.q.

1) $\forall$ feuilles u,v, $dist_T(u,v) = D_{uv}$

└ somme des longueurs de branches sur le chemin u,v dans T

2) Soit r la racine de T. Alors $\forall$ feuilles u,v, $dist_T(u,r) = dist_T(v,r)$