Distances de réarrangement

27 novembre 2023 08:48

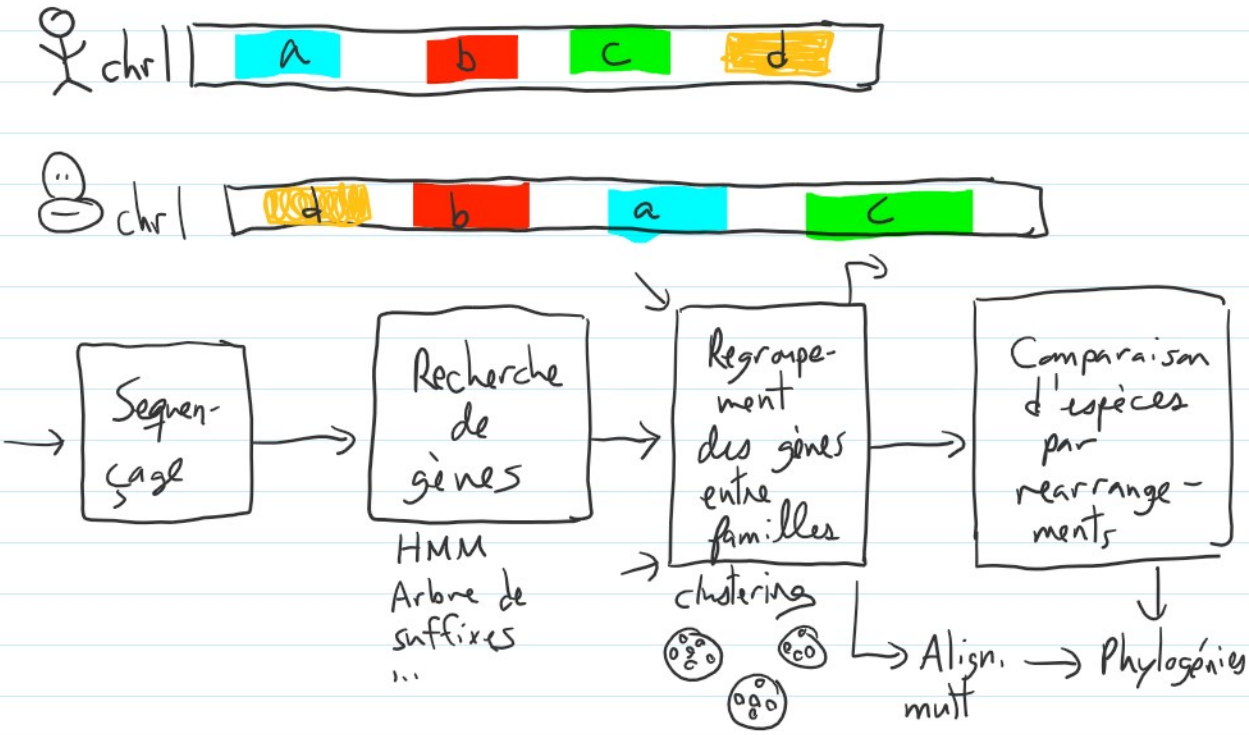

But: étant donné 2 séquences sur alphabet <u>arbitraire</u>
↳ ensembles de séquences
trouver un nombre min. d'<u>opérations</u> pour
changer une séquence en l'autre.

Séquence: suite des gènes trouvés sur une espèce
ex: S = abcde

1 symbole = 1 gène
1 séquence = 1 chromosome

Télomère: extrémité d'un chromosome
détermine le début et la fin
du chr.
symbole spécial •

au chr.
symbole spécial •

ex: S = abcde avec télomère → • abcde •

• Un gène peut être signé ou non-signé

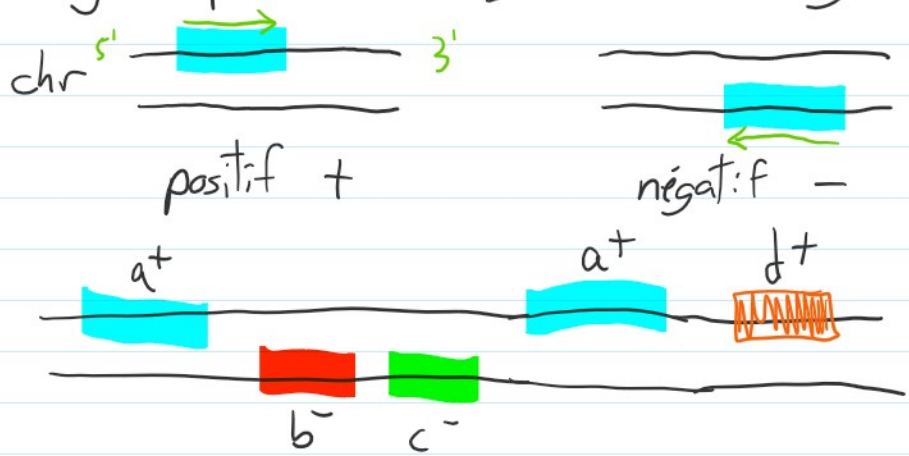

$S = a^+ b^- c^- a^+ d^+$

• Quelques opérations génomique

Intrachromosomique (affectent 1 chr.)

a) Inversion

Renverser une sous-chaîne quelconque

ex: abcdef → abedcf

Version signée
└ renverse la sous-chaîne et change des signes

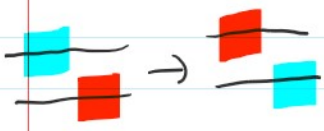

signes

$a^+b^+c^-d^-e^+f^- \rightarrow a^+b^+e^-d^+c^+f^-$

b) Insertion/deletion en bloc

Ins.: ajouter une sous-chaîne quelconque abcd → abefcd
Del.: supprime une sous-chaîne quelconque abcd → ad

c) Transposition

Prend 2 sous-chaîne consécutives, les échanger

ABCD → ACBD

ex: abcdefg → aefbcdg

d) Duplication

Prend un segment, le copie-colle (ailleurs)

ex: abcdefg → abcdefbcdg

• Interchromosomique

e) Fusion / fission

Fusion chr1 chr2

chr' concatène 2 chr.

Fission séparé 2 chr.

Fission ↳ sépare 2 chr.

f) Translocation

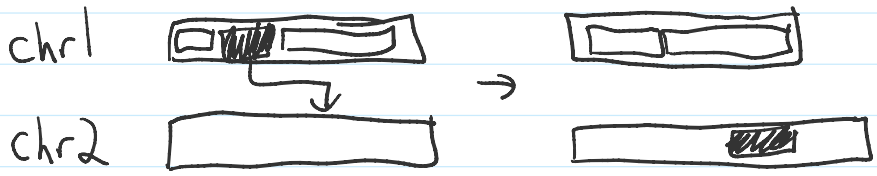

Coupe un segment de chr1 et le colle sur chr2.

Problème algorithmique

<u>Entrée</u> : génomes A et B (ensembles de séquences)
ensemble d'opérations permises OP
ex: OP = {inversion, deletion}

<u>Sortie</u> : # min. d'opérations dans OP
pour transformer A en B.

ex: OP = {inversion, deletion}

$A = a \underbrace{b\ c\ d\ e}_{\text{inversion}}\ f\ g$

$a\ e\ d\ c\ \underbrace{b\ f}_{\text{del}}\ g$

$\underbrace{a\ e\ d}_{\text{inv}}\ c\ g$

$B = d\ e\ a\ c\ g$

- Quelques complexités

OP	Complexité
Inversion	Génes non-signés : NP-complet

Inversion — Gènes non-signés : NP-complet
Signés : $O(n)$

Transposition, Dup $\rightarrow$ NP-complet

Deletion, Insertion $\rightarrow$ polynomial exercice

Ins. + Del $\rightarrow$ trivial

DCJ $\rightarrow O(n)$

<u>DCJ</u> : double-cut and join

- opération "synthétique"
- permet de simuler la plupart des autres op.
- n'a pas de justification biologique
- opère sur les adjacences entre gènes

<u>Adjacence</u> : Dans un génome signé, chaque gène a 2 extrémités,
d = début f = fin

On dénote :

$$a^+ = a_d a_f$$

$$a^- = a_f a_d$$

autres notation
$a_t a_h$
$a_- a_+$

ex : • $a^+ b^- c^+$ •

$\bullet\, a_d a_f b_f b_d c_d c_f \,\bullet$

Une <u>adjacence</u> est une paire non-ordonnée de symboles consécutifs dans cette représentation.

$\bullet$ adj. de $\bullet a^+ b^- c^+ \bullet$: $\{\bullet, a_d\}$ $\{a_d, a_f\}$ $\{a_f, b_f\}$ $\{b_f, b_d\}$ $\{b_d, c_d\}$, $\{c_d, c_f\}$ $\{c_f, \bullet\}$

DCJ: prend deux adj. et les "croise"

$$\begin{matrix}\{a_d, a_f\} \\ \{b_d, c_d\}\end{matrix} \longrightarrow \begin{matrix}\{a_d, c_d\} \\ \{a_f, b_d\}\end{matrix}$$