Sequençage algo

26 septembre 2023 08:50

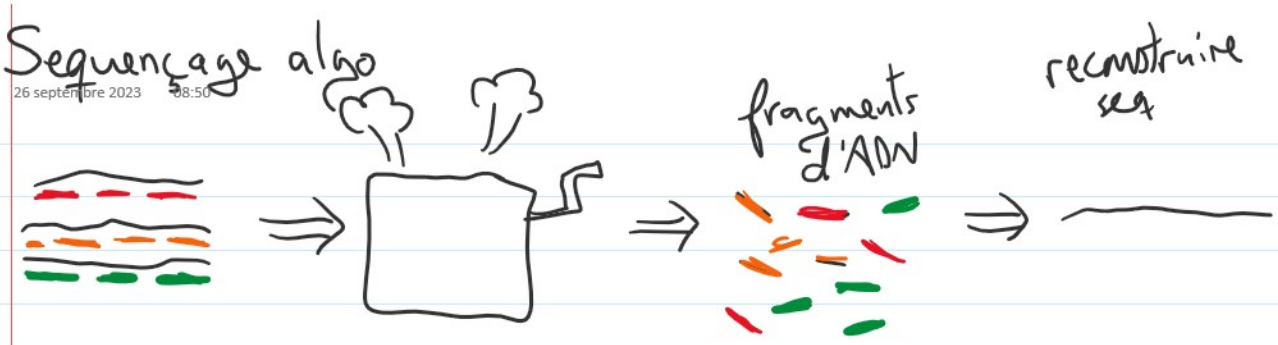

Deux types de sequençage :

→ de Novo : génome inconnu

avec référence : génome "typique" connu
voir les différences de votre génome
avec le typique

Problème de l'assemblage

<u>Entrée</u> : séquence $r_1, r_2, \ldots, r_n$, appelés "reads"
(fragments de chromosomes, chevauchants)

<u>Sortie</u> : séquence originale

Plusieurs formulations

└ + courte superséquence

<u>Sortie</u> : séquence S de longueur minimum
qui contient $r_1, r_2, \ldots, r_n$ (comme sous-chaînes)

ex : r_1 = ACCG r_2 = CGCT r_3 = GCTA r_4 = GACC

r_1 r_3

GACCGCTA

r_4 r_2

r_4 r_2

Ce pb. est NP-complet (probablement pas d'algo polynomial)

Méthode de résolution : réduction au commis voyageur.

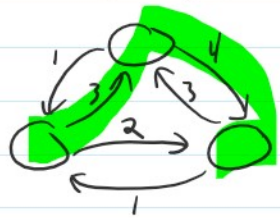

- On définit $\text{overlap}(r_i, r_j)$ = taille du + long suffixe de r_i qui est un préfixe de r_j

$\text{overlap}(ACGGT, GGTTTT) = 3$

- On construit un graphe dirigé ($\rightarrow$)

sommet arête

$G = (V, E)$ où

V = sommets $= \{r_1, r_2, \ldots, r_n\}$

$E = \{(r_i, r_j) : 1 \leq i, j \leq n,\ i \neq j\}$

poids sur $(r_i, r_j) = \text{overlap}(r_i, r_j)$

$r_1 = ACCG$ $r_2 = GCTA$ $r_3 = TACC$

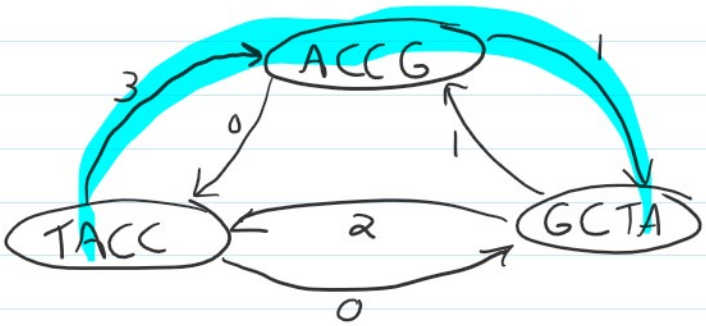

But : trouver un chemin Hamiltonien - qui passe une fois par sommet - de poids maximum

de poids maximum

Glouton: TACCGCTA

Optimal: GCTACCG

Glouton: démarrer avec l'arête de poids max, puis tjrs emprunter l'arête dispo. de poids max

<u>Thm</u>: algo glouton est une $\frac{1}{4}$-approximation
sol glouton $\geq \frac{1}{4}$ optimal

<u>Conjecture</u>: algo glouton est une $\frac{1}{2}$-approx.

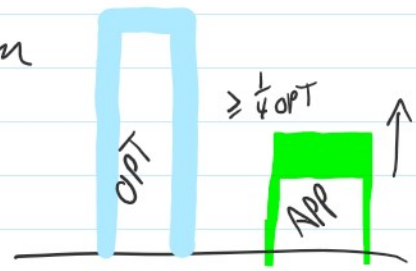

Décomposition en k-mer

- k-mer : séq. de longueur k
- Lister tous les k-mers de nos reads

r_i : ACCGT r_j : ACGTT

ACC CCG CGT ACG CGT GTT

- On construit un graphe $G=(V,E)$ où

V = tous les k-mers (avec répétition ou non)

$E = \{(X,Y) : X = aZ \text{ et } Y = Zb, \text{ où } a,b \in \Sigma\}$
avec Σ l'alphabet

$X \to Y$ chevauchement de taille $k-1$
ACG → CGT

ex: ACG CGC GCA CAC ACG CGT GTT

Ex: ACG CGC GCA CAC ACG CGT GTT

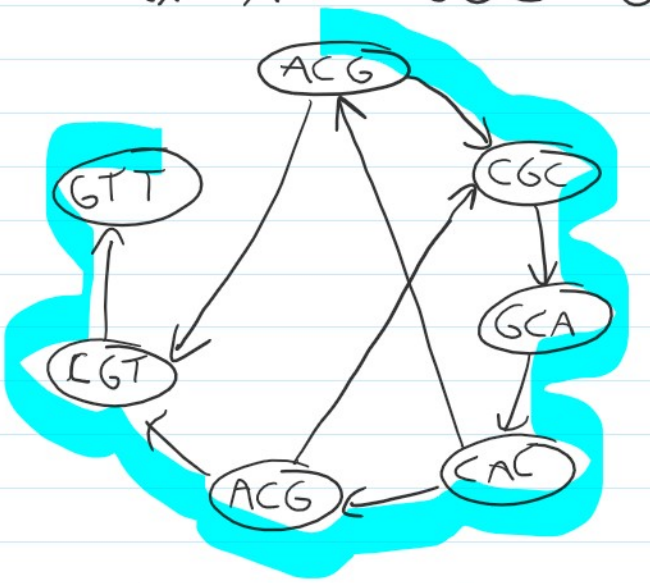

But: trouver un chemin Hamiltonien.

Quand même NP complet

ACGCACGTT

seq. long. n
$\Rightarrow$ # k-mers $n-k+1$

Graphes de Bruijn

- Autre modélisation
- Au lieu que k-mer = sommet
  k-mer = arête

Graphe $G=(V,E)$

V = tous les $k-1$ mers qui apparaissent dans nos reads

$E = \{(X,Y)$: il existe un k-mer Z dans nos reads tel que $Z = Xa$ et $Z = bY$, $a,b \in \Sigma\}$

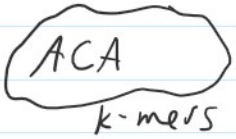

Une arête est répétée autant de fois qu'un k-mer est présent.

k-mer est présent.

ex: k-mers : CGT ACG CTA ACT TAC $k=3$

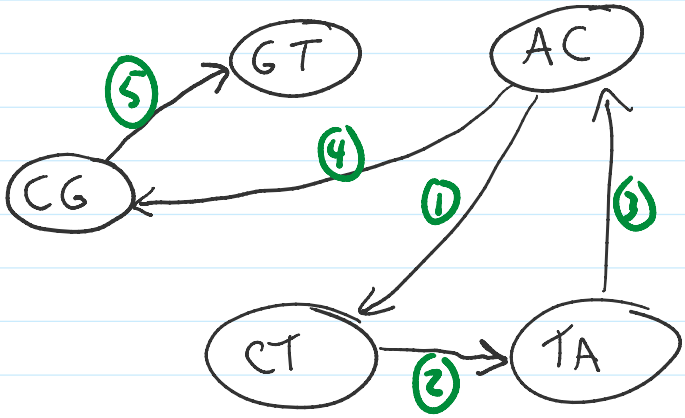

But : trouver une chemin Eulérien, i.e. qui passe exactement une fois par arête.

ACTACGT